Báo cáo EDA ngắn: UCI Bike Sharing và Tetouan City

Ngày: 14/10/2026

1. Tổng quan

Hai dataset được chọn cho nghiên cứu time series forecasting:

Dataset	Tần suất	Quy mô	Target
UCI Bike Sharing	1 giờ	17.379 dòng	Số lượt thuê xe `cnt`
Tetouan City Power Consumption	10 phút	52.416 dòng	Phụ tải Zone 1, 2, 3

Cả hai đều có dữ liệu thời gian, biến ngoại sinh, giấy phép CC BY 4.0 và nguồn UCI chính thức.

2. UCI Bike Sharing

Dữ liệu ghi nhận số lượt thuê xe tại Washington DC trong giai đoạn 2011–2012. Biến ngoại sinh gồm thời tiết và thông tin lịch.

Kết quả EDA

- Không có NA trong ô dữ liệu và không có timestamp trùng.
- Có 165 mốc giờ bị thiếu trên 17.544 mốc kỳ vọng, tương đương 0,94%.
- Target `cnt` có trung bình 189,5, skewness 1,28 và kurtosis 1,42.
- Trung bình theo giờ năm 2012 cao hơn năm 2011 khoảng 63,2%, cho thấy drift theo thời gian.
- Mùa vụ ngày và tuần rõ: ACF lag 24 = 0,819 và lag 168 = 0,876.
- `casual + registered = cnt` ở mọi dòng. Hai cột này gây rò rỉ target và phải loại khỏi input.

Xử lý đề xuất

- Loại `instant`, `casual`, `registered`.
- Dựng lại lưới giờ và đánh dấu các mốc thiếu.

- Giữ các đỉnh nhu cầu thật; không xóa outlier tự động.
- Có thể giữ một trong hai biến `temp` và `atemp` vì chúng gần trùng nhau.
- Tạo đặc trưng giờ, ngày trong tuần, ngày làm việc và lag $^{24}/_{168}$.
- Chia train/validation/test theo thời gian, không random split.

3. Tetouan City Power Consumption

Dữ liệu ghi nhận phụ tải điện của ba vùng phân phối tại Tetouan, Morocco, trong năm 2017. Dataset có nhiệt độ, độ ẩm, tốc độ gió và các biến bức xạ.

Kết quả EDA

- Có 52.416 dòng theo tần suất 10 phút.
- Không có mốc thời gian thiếu, timestamp trùng hoặc NA.
- Target trung bình:
  - Zone 1: 32.345
  - Zone 2: 21.043
  - Zone 3: 17.835
- Zone 1 và Zone 2 tương đối cân bằng; Zone 3 lệch phải hơn với skewness 1,024.
- Ba vùng có tương quan dương. Pearson giữa Zone 1 và Zone 2 là 0,835; giữa Zone 1 và Zone 3 là 0,751.
- Sau khi resample theo giờ, Zone 1 có ACF lag 24 = 0,963 và lag 168 = 0,953, cho thấy mùa vụ ngày và tuần rất rõ.
- Các biến liên quan Zone 1 mạnh nhất theo Spearman là Temperature = 0,433, Humidity = -0,300 và general diffuse flows = 0,261.

Xử lý đề xuất

- Parse `DateTime` và kiểm tra bước 10 phút.
- Chuẩn hóa riêng từng Zone trước khi huấn luyện multi-output.
- Tạo đặc trưng giờ, thứ trong tuần và tháng.
- Có thể giữ dữ liệu 10 phút hoặc resample về giờ để so sánh với Bike Sharing. Cần ghi rõ resample bằng trung bình hay tổng.
- Thử dự báo từng Zone và dự báo đồng thời ba Zone.

4. So sánh và hướng mô hình

- **Bike Sharing:** một target đếm theo giờ, có drift và thiếu một số mốc thời gian.
- **Tetouan:** ba target phụ tải liên tục, dữ liệu sạch, có tương quan giữa các vùng và tần suất cao hơn.

Nên bắt đầu bằng naive và seasonal-naive, sau đó thử GRU/LSTM hoặc TCN nhỏ. Không nên dùng Transformer lớn ngay từ đầu vì hai dataset đều tương đối nhỏ.

Khi đánh giá:

- Chia dữ liệu theo thời gian.
- Fit scaler chỉ trên tập train.
- Báo cáo MAE, RMSE và sMAPE.
- Ghi rõ lookback, forecast horizon, tần suất và cách xử lý timestamp thiếu hoặc resample.

5. Kết luận

UCI Bike Sharing phù hợp cho demand forecasting theo giờ. Tetouan City phù hợp cho load forecasting đa biến và multi-output. Đây là một cặp dataset nhẹ, dễ triển khai trên máy yếu và đủ để nghiên cứu các mô hình time series cơ bản đến deep learning nhỏ.

Tài liệu tham khảo

1. Fanaee-T, H., & Gama, J. (2014). *Event labeling combining ensemble detectors and background knowledge*. https://doi.org/10.1007/s13748-013-0040-3
2. Fanaee-T, H. (2013). *Bike Sharing* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5W894
3. Salam, A., & El Hibaoui, A. (2018). *Comparison of Machine Learning Algorithms for the Power Consumption Prediction: Case Study of Tetouan city*. https://doi.org/10.1109/IRSEC.2018.8703007
4. Salam, A., & El Hibaoui, A. (2023). *Power Consumption of Tetouan City* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5B034