Khảo sát dataset cho bài toán dự báo nhu cầu

Nguyễn Lý Trường Sơn, 11/10/2026.

1. Thông tin dataset

Trường	UCI Bike Sharing (giờ)	M5 Forecasting – Accuracy	FreshRetailNet-50K
Nguồn / link	UCI, dataset 275, DOI 10.24432/C5W894 [1][2]	Kaggle [3]; Competitors' Guide [4]; IJF [5]	Hugging Face `Dingdong-Inc/FreshRetailNet-50K` [6]; arXiv:2505.16319 [7]
Lĩnh vực / bài toán	Lượt thuê xe đạp mỗi giờ (Washington D.C.)	Doanh số đơn vị hằng ngày của Walmart	Doanh số hàng tươi sống, có nhãn hết hàng theo giờ
Số mẫu	1 chuỗi, 17,379 dòng (giờ), 2011–2012	30,490 chuỗi sản phẩm × cửa hàng (42,840 chuỗi trên 12 cấp) × 1,941 ngày có nhãn công khai [4][5]	50,000 chuỗi cửa hàng × sản phẩm; 4,500,000 dòng train + 350,000 dòng eval [6]; 97 ngày (90 train + 7 eval)
Input dimension	17 cột gốc; 12–13 cột dùng được sau khi loại ID và các cột rò rỉ	3 file; sau khi ghép dạng dài: 22 cột (lịch, sự kiện, SNAP, giá, ID phân cấp; phép tính, dựa trên [4])	19 cột, trong đó 2 cột là mảng 24 giờ; 65 giá trị/dòng khi trải phẳng [6]
Target	`cnt` (số nguyên, 1–977)	Doanh số đơn vị/ngày; horizon 28 ngày [4]	`sale_amount` (số thực, đã nhân hệ số toàn cục) [6]; horizon 7 ngày [7]
Kiểu dữ liệu	Time series 1D, tần suất giờ	Nhiều chuỗi theo ngày, phân cấp	Nhiều chuỗi theo ngày, kèm hồ sơ giờ (ngày × 24)
Split	Không có split chính thức; đề xuất chia theo thời gian tại 2012-09-01 kèm rolling-origin	Chính thức: train d_1–d_1913, val d_1914–d_1941, test d_1942–d_1969 [5]	Chính thức: tách train/eval [6]; theo dữ liệu: train 2024-03-28 → 06-25 (90 ngày), eval 06-26 → 07-02 (7 ngày)
Kích thước	1.1 MB [1]	5 file CSV, 450.47 MB [3]; ma trận doanh số khoảng 118 MB (int16, ước tính)	115 MB parquet [6]
Giấy phép	CC BY 4.0 [1]	Chỉ dùng phi thương mại, không phân phối lại [3]	CC BY 4.0 [6]

Vấn đề cần xử lý

Bike Sharing:

- `casual` + `registered` = `cnt`, nên phải loại hai cột này để tránh rò rỉ.
- Trung bình `cnt` mỗi giờ tăng 63.2% (143.79 → 234.67) từ 2011 sang 2012, vì vậy bắt buộc chia theo thời gian.
- Thiếu 165 giờ; thời tiết đã chuẩn hóa về [0, 1] [1].

M5:

- Định dạng rộng (1,941 cột ngày); dạng dài có 59,181,090 dòng, tốn bộ nhớ.
- Chuỗi gián đoạn, nhiều số 0 [5]; cần tách số 0 thật khỏi giai đoạn trước khi mở bán [4].

FreshRetailNet-50K:

- Doanh số bị kiểm duyệt: 19.9% số giờ 6–22h (train) ở trạng thái hết hàng.

- `holiday_flag` là cờ ngày nghỉ: = 1 vào cuối tuần (25/26 ngày cuối tuần trong train; Chủ nhật 07/04 là ngày làm bù) và 6 ngày lễ chính thức của Trung Quốc rơi vào ngày thường (Thanh Minh, Lao động, Đoan Ngọ 2024) [7][8]; nên tách thêm biến thứ trong tuần.
- `discount` có giá trị 0 và > 1, trái quy ước [6].
- Lịch sử 97 ngày (90 train + 7 eval); doanh số đã chuẩn hóa. Bài báo ghi 863 SKU [7], thẻ dữ liệu và dữ liệu có 865 [6].

2. Ma trận so sánh góc nhìn

Góc nhìn	Bike Sharing	M5	FreshRetailNet-50K
Tần suất	Giờ	Ngày	Ngày (có hồ sơ giờ)
Quy mô / số chuỗi	1	30,490 (42,840 khi tính phân cấp)	50,000
Độ dài lịch sử	2 năm	Khoảng 5.4 năm	97 ngày (90 train + 7 eval)
Độ thưa / số 0	Không có số 0	Cao, gián đoạn [5]	Thấp (4.46% số ngày bằng 0)
Biến ngoại sinh	Thời tiết, lịch	Giá, sự kiện, SNAP	Khuyến mãi, thời tiết, cờ hoạt động
Cấu trúc phân cấp	Không	12 cấp [5]	Thành phố > cửa hàng; 5 cấp sản phẩm
Dịch chuyển phân phối / xu hướng	Rõ (+63.2% trung bình `cnt` mỗi giờ, 2012 so với 2011)	Chưa đo (lịch sử 5.4 năm)	Không đánh giá được dài hạn (97 ngày)
Nhu cầu bị kiềm duyệt	Không	Không có nhãn	Có nhãn theo giờ
Benchmark công bố	Không có chuẩn chung	Bảng xếp hạng, WRMSSE [5]	TFT, WAPE nhóm Overall: 31.75% (doanh số thô) → 29.02% (nhu cầu khôi phục bằng TimesNet); chỉ đánh giá trên giai đoạn còn hàng [7, Bảng 3]
Tính mới	Thấp	Thấp	Cao (công bố 2025)
Chi phí tính toán	Thấp	Cao (cần lấy mẫu con)	Trung bình (tập con 1,000 chuỗi: khoảng 14–20 phút trên 8 CPU; toàn bộ 50,000 chuỗi cần nhiều hơn)
Giấy phép	CC BY 4.0	Phi thương mại	CC BY 4.0

Ba dataset bổ sung nhau về tần suất, quy mô và dạng sai lệch của dữ liệu (xu hướng, gián đoạn, kiểm duyệt).

3. Đánh giá độ phù hợp

Thang đánh giá: Đạt / Đạt một phần / Hạn chế.

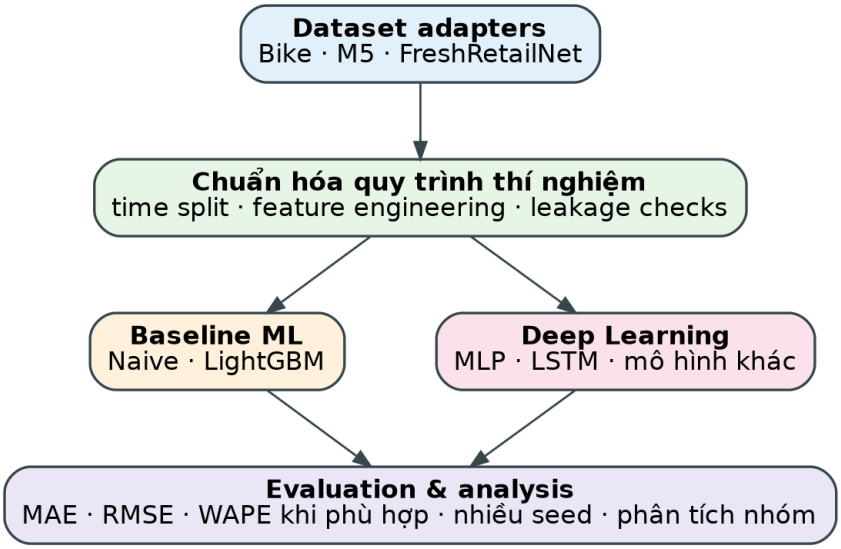
Tiêu chí	Bike	M5	FreshRetailNet
Số lượng mẫu	Đạt một phần (1 chuỗi)	Đạt	Đạt
Input dimension	Đạt một phần (ít đặc trưng)	Đạt	Đạt
Kiểu dữ liệu time series	Đạt	Đạt	Đạt

Tiêu chí	Bike	M5	FreshRetailNet
Bài toán hồi quy / dự báo	Đạt	Đạt	Đạt
Đủ cấu trúc cho học sâu khai thác	Hạn chế (1 chuỗi, ít chiều)	Đạt một phần (đủ cấu trúc, chi phí cao)	Đạt
Khả thi trên CPU/Colab	Đạt	Hạn chế (bắt buộc lấy mẫu con)	Đạt một phần (tập con 1,000 chuỗi khả thi; toàn bộ cần thêm tài nguyên)
Giấy phép, trích dẫn	Đạt	Đạt một phần (phi thương mại)	Đạt (bài báo chưa bình duyệt)
Benchmark	Hạn chế	Đạt	Đạt một phần
Tính mới	Hạn chế	Hạn chế	Đạt

Kết luận. FreshRetailNet-50K làm dataset chính; M5 làm kiểm chứng; Bike Sharing làm đối chứng một chuỗi.

Phương án đề xuất: cả ba dataset dùng cùng một câu hỏi nghiên cứu. FreshRetailNet-50K được phân tích sâu (ablation, nhiều seed, kiểm định thống kê). M5 (lấy mẫu con) và Bike Sharing chỉ chạy cấu hình chính để kiểm chứng kết luận.

4. Khung phương pháp dự kiến



Hình 1. Khung phương pháp dự kiến

Mọi mô hình dùng chung cách chia theo thời gian, đặc trưng và cửa sổ đánh giá; kết quả báo cáo qua nhiều seed, kèm kiểm định thống kê.

Tài liệu tham khảo

[1] H. Fanaee-T, "Bike Sharing," UCI Machine Learning Repository, 2013, doi: 10.24432/C5W894. [Online]. Available: https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset. [Accessed: Oct. 11, 2026].

[2] H. Fanaee-T and J. Gama, "Event labeling combining ensemble detectors and background knowledge," *Progress in Artificial Intelligence*, vol. 2, no. 2–3, pp. 113–127, Jun. 2014 (published online Nov. 2013), doi: 10.1007/s13748-013-0040-3.

[3] A. Howard, inversion, S. Makridakis, and vangelis, "M5 Forecasting - Accuracy," Kaggle, 2020. [Online]. Available: https://www.kaggle.com/competitions/m5-forecasting-accuracy (Data: https://www.kaggle.com/competitions/m5-

forecasting-accuracy/data; Rules: https://www.kaggle.com/competitions/m5-forecasting-accuracy/rules). [Accessed: Oct. 11, 2026].

[4] University of Nicosia (MOFC), "The M5 competition: Competitors' guide," 2020. [Online]. Available: https://github.com/Mcompetitions/M5-methods/blob/master/M5-Competitors-Guide.pdf. [Accessed: Oct. 11, 2026].

[5] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "M5 accuracy competition: Results, findings, and conclusions," *International Journal of Forecasting*, vol. 38, no. 4, pp. 1346–1364, 2022, doi: 10.1016/j.ijforecast.2021.11.013.

[6] Dingdong-Inc, "FreshRetailNet-50K," Hugging Face dataset card, v1.0, 2025. [Online]. Available: https://huggingface.co/datasets/Dingdong-Inc/FreshRetailNet-50K. [Accessed: Oct. 11, 2026].

[7] Y. Wang, J. Gu, L. Long, X. Li, L. Shen, Z. Fu, X. Zhou, and X. Jiang, "FreshRetailNet-50K: A stockout-annotated censored demand dataset for latent demand recovery and forecasting in fresh retail," arXiv:2505.16319v5 [cs.LG], 2025. [Online]. Available: https://arxiv.org/abs/2505.16319. [Accessed: Oct. 11, 2026].

[8] General Office of the State Council of the People's Republic of China, "国务院办公厅关于2024年部分节假日安排的通知 (Notice on the arrangement of certain holidays in 2024)," Guo Ban Fa Ming Dian [2023] No. 7, Oct. 25, 2023. [Online]. Available: https://www.gov.cn/zhengce/content/202310/content_6911527.htm. [Accessed: Oct. 11, 2026].